

Laporan Praktikum Kontrol Cerdas Minggu Ke-4

Nama : Ardi Septian rahmadani
NIM : 224308052
Kelas : TKA 7C
Akun Github (Tautan) : <https://github.com/ardiseptian224308052tka-eng>

1. Judul Percobaan

Reinforcement Learning for Autonomous Control

2. Tujuan Percobaan

- Memahami konsep dasar *Reinforce Learning* (RL) dalam sistem kendali
- Mengimplementasikan agen RL menggunakan algoritma *Deep Q-Network* (DQN).
- Menggunakan *OpenAI Gym* sebagai simulasi lingkungan untuk pelatihan RL.
- Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.

Menggunakan GitHub untuk *version control* dan dokumentasi praktikum

3. Landasan Teori

Reinforcement Learning (RL) adalah metode *machine learning* di mana agen belajar sendiri dengan berinteraksi langsung dengan lingkungannya. Kontras dengan *supervised learning* yang memakai label eksplisit, RL mengharuskan agen untuk bereksperimen melalui coba-coba dan menerima umpan balik berupa *reward* atau *penalty*. Tujuan dari proses ini adalah agar agen dapat mengembangkan kebijakan optimal yang akan memaksimalkan total *reward* dalam jangka waktu panjang.

Deep Q-Network (DQN) adalah algoritma dalam Reinforcement Learning yang ditingkatkan dengan mengintegrasikan Q-Learning bersama jaringan saraf dalam (*deep neural networks*). Inovasi ini memungkinkan agen untuk berhasil belajar dalam lingkungan yang sangat besar dan kompleks—sebuah keterbatasan pada Q-Learning yang hanya mengandalkan *Q-table*. Tujuan utama DQN adalah

menentukan urutan tindakan optimal yang menghasilkan total hadiah terbesar dalam jangka panjang. Algoritma ini bekerja dengan menggunakan fungsi nilai Q untuk memprediksi seberapa baik sebuah tindakan dalam keadaan tertentu. Penggunaan DQN mencakup berbagai skenario, seperti *CartPole*, simulasi pendaratan di *LunarLander-v2*, dan tugas berbasis momentum di *MountainCar-v0*

LunarLander-v2 adalah lingkungan uji dari *OpenAI Gym* yang dirancang untuk mengevaluasi algoritma RL. Dalam lingkungan ini, agen bertugas mengatur pendaratan wahana luar angkasa di permukaan Bulan. Agen mendapatkan *reward* berdasarkan seberapa baik dan *efisien* pendaratan (terutama efisiensi bahan bakar), dan dikenakan penalti jika pendaratan buruk atau melenceng dari area yang ditentukan. Sementara itu, *MountainCar-v0* adalah lingkungan lain di mana agen harus mengumpulkan momentum dengan menggerakkan mobil maju-mundur (ke kiri, kanan, atau diam) agar mampu mencapai puncak bukit. Agen menerima hadiah negatif pada setiap langkah yang diambil, sehingga mendorong agen untuk menyelesaikan tugas secepat mungkin sebelum batas langkah terlampaui.

4. Analisis dan Diskusi



Dalam mata kuliah Praktikum Kontrol Cerdas minggu keempat, kami mengimplementasikan algoritma Deep Q-Network (DQN) untuk menyelesaikan masalah *MountainCar-v0* dalam kerangka *reinforcement learning*, di mana agen dilatih untuk mencapai puncak bukit dengan memanfaatkan pengalaman yang dikumpulkan saat bermain. Logika pembelajaran diatur dalam kelas *DQNAgent* yang menggunakan penyangga memori (*memory buffer*) untuk *experience replay*, memastikan agen belajar secara stabil dari pengalaman sebelumnya. Proses pengambilan keputusan diatur oleh parameter epsilon (ϵ), yang secara bertahap berkurang (*epsilon_decay*), menyeimbangkan antara eksplorasi (aksi acak) di awal dan eksploitasi (aksi berdasarkan pengetahuan) di kemudian hari. Pelatihan dilakukan di lingkungan *MountainCar-v0* dengan visualisasi aktif (*human render*), di mana agen mengamati keadaan, memilih aksi, menerima *reward*, dan menyimpan pengalaman, dengan *reward* dirancang untuk





memotivasi pencapaian tujuan. Secara keseluruhan, program ini berhasil menerapkan DQN menggunakan *experience replay* dan strategi ϵ -greedy, meskipun terdapat potensi optimasi pada sistem *reward* (misalnya, memberi hadiah saat mendekati puncak) dan peningkatan efisiensi dengan menonaktifkan tampilan visual selama sesi pelatihan yang panjang.

5. Assignment

Pada tahap ini, algoritma Deep Q-Network (DQN) dimodifikasi dengan menambahkan *target network* guna meningkatkan stabilitas pelatihan. Dengan adanya *target network*, pembaruan nilai Q menjadi lebih konsisten sehingga agen dapat belajar lebih efektif tanpa mengalami osilasi besar. Selain diuji pada *CartPole-v1*, agen juga dicoba pada *LunarLander-v2* dan *MountainCar-v0*. Hasil pengujian menunjukkan tingkat kesulitan yang bervariasi. Pada *CartPole*, agen relatif cepat belajar menjaga keseimbangan, sementara pada *LunarLander* dibutuhkan lebih banyak episode untuk menghasilkan strategi pendaratan yang baik. Adapun *MountainCar* menjadi tantangan tersendiri karena agen harus memanfaatkan momentum untuk mencapai puncak bukit, sehingga proses belajar berlangsung lebih lambat.

6. Data dan Output Hasil Pengamatan

No	Parameter	CartPole-v1	MountainCar-v0
1.	Waktu Pelatihan	Agen relatif cepat mencapai performa optimal setelah beberapa ratus episode.	Agen membutuhkan lebih banyak episode karena lingkungan lebih kompleks dan reward jarang didapat.
2.	Jumlah Episode	1000 episode (agen sudah mampu menjaga tiang tetap seimbang). 	1000 episode (agen mulai bisa mencapai bendera, tapi butuh eksplorasi lebih lama). 
3.	Skor per Episode (Testing)	Skor rata-rata meningkat signifikan (contoh: 43, 85, 128, hingga >200).	Skor awal rendah ($\pm$ -200), meningkat perlahan

			mendekati target optimal setelah ratusan episode. 
4.	Epsilon (ϵ) – Exploration Rate	Nilai epsilon menurun dari 1.0 $\rightarrow$ 0.01 secara bertahap, menunjukkan transisi dari eksplorasi ke eksploitasi. 	Sama, menurun dari 1.0 $\rightarrow$ 0.01, namun proses eksplorasi lebih lama karena reward jarang muncul. 
7.	Hasil Visualisasi	Agan berhasil menjaga tiang tetap tegak dalam simulasi CartPole. 	Agan mampu menggerakkan mobil naik-turun bukit hingga akhirnya mencapai bendera (goal). 

7. Kesimpulan

Dari hasil pengujian dapat disimpulkan bahwa algoritma Deep Q-Network (DQN) mampu mengendalikan lingkungan simulasi secara efektif, meskipun setiap environment memiliki tingkat kesulitan yang berbeda. Pada CartPole-v1, agen relatif cepat mencapai kinerja optimal karena pola reward yang konsisten. Sebaliknya, pada MountainCar-v0 dibutuhkan lebih banyak episode serta

strategi eksplorasi yang lebih baik untuk mencapai target. Temuan ini menegaskan bahwa semakin kompleks suatu environment, semakin besar pula tantangan yang dihadapi dalam proses pembelajaran agen RL.

8. Saran

Untuk meningkatkan efektivitas agen dalam menaklukkan MountainCar-v0, beberapa aspek penting dapat dioptimalkan. Peningkatan dapat dilakukan dengan menyesuaikan parameter kunci seperti nilai gamma (faktor diskonto untuk *reward* di masa depan), laju epsilon decay (kecepatan transisi dari eksplorasi ke eksploitasi), dan ukuran *memory buffer*. Penyesuaian ini bertujuan agar agen dapat menemukan strategi optimal dengan lebih cepat dan efisien. Selain itu, mengingat *MountainCar-v0* membutuhkan banyak episode pelatihan, disarankan untuk menonaktifkan tampilan visual (*human render*) selama proses pelatihan agar tidak memperlambat kinerja. Visualisasi sebaiknya hanya diaktifkan kembali saat evaluasi untuk memantau hasil akhir. Secara keseluruhan, perbaikan ini diharapkan menghasilkan agen yang belajar lebih cepat, lebih stabil, dan lebih efisien dalam menyelesaikan tantangan tersebut.

10. Daftar Pustaka

- Malik, M., 2021. DETEKSI SUHU TUBUH DAN MASKER WAJAH DENGAN MLX90614, OPENCV, KERAS/TENSORFLOW, DAN DEEP LEARNING.. *Jurnal Engine: Energi, Manufaktur, dan Material*, p. 19.
- Gou, S. Z., & Liu, Y. (2019). *DQN with model-based exploration: Efficient learning on environments with sparse rewards* (No. arXiv:1903.09295).arXiv. <https://doi.org/10.48550/arXiv.1903.09295>
- Norman, P. (n.d.). *Training reinforcement learning model with custom OpenAI gym for IIoT scenario*.
- Putra, R. A., Syahbana, Y. A., & Ananda. (2024). Implementasi Algoritma Deep Q- Network (DQN) pada Lampu Lalu Lintas Adaptif Berdasarkan Waktu Tunggu dan Arus Kendaraan. *The Indonesian Journal of Computer Science*, 13(5). <https://doi.org/10.33022/ijcs.v13i5.4372>